

Adaptación y Evaluación de la Arquitectura U-Net para la Segmentación Binaria de Lesiones Cutáneas en el Dataset ISIC 2018

Alejandro Zapata

Universidad de Antioquia, Departamento de Ingeniería Electrónica
Correo: alejandro.zapata6@udea.edu.co

Resumen—Este informe presenta el desarrollo, adaptación y evaluación crítica de una red neuronal convolucional profunda basada en la arquitectura U-Net para la segmentación automatizada de lesiones en la piel utilizando el dataset ISIC 2018. El modelo original, inicialmente diseñado para segmentación multiclase de elementos anatómicos en mascotas, fue reconfigurado hacia una tarea de segmentación binaria estricta mediante modificaciones en la capa de salida, funciones de costo optimizadas y métricas de solapamiento espacial. Tras un entrenamiento de 15 épocas utilizando aceleración por hardware (GPU T4), el sistema convergió de manera estable alcanzando un Coeficiente DICE de 0.7077 en el conjunto de validación. Adicionalmente, se presenta un análisis de extremos discriminando casos de éxito frente a falsos negativos absolutos, permitiendo concluir sobre las limitaciones impuestas por el desbalance de clases y la función de pérdida por entropía cruzada.

Index Terms—U-Net, ISIC 2018, Segmentación Binaria, Coeficiente DICE, Deep Learning, Diagnóstico Médico por Computador.



1. INTRODUCCIÓN

La detección temprana de anomalías y patologías cutáneas como el melanoma maligno es una tarea crítica en la medicina dermatológica moderna. El uso de herramientas basadas en Inteligencia Artificial y Deep Learning permite complementar el criterio del especialista, reduciendo la variabilidad inter-observador mediante la delimitación matemática precisa de los bordes lesionados.

El propósito principal de este proyecto de investigación radica en demostrar la versatilidad de la arquitectura *U-Net*, evidenciando cómo un diseño estructural concebido para tareas genéricas de visión por computador puede adaptarse rigurosamente a un dominio médico complejo. A lo largo de este documento, se desglosa el protocolo experimental, la gestión de datos, las métricas de rendimiento y una discusión metodológica de los resultados negativos obtenidos durante la evaluación.

2. METODOLOGÍA Y ARQUITECTURA

2.1. Preprocesamiento del Dataset ISIC 2018

El dataset de entrenamiento fue segmentado de manera jerárquica y ordenada. Las imágenes originales dermatoscópicas en formato RGB fueron normalizadas a tensores en el rango de $[0,0, 1,0]$ y redimensionadas a una resolución espacial homogénea de 256×256 píxeles.

Las máscaras de segmentación (*Ground Truth*), provistas originalmente en escala de grises con valores enteros en el intervalo $[0, 255]$, sufrieron un proceso de binarización estricta. Para garantizar la consistencia analítica, se aplicó una interpolación por el vecino más cercano (*Nearest Neighbor*)

durante el cambio de escala espacial evitando la distorsión geométrica periférica, seguido de la aplicación de una función umbralizadora formalizada como:

$$M(x, y) = \begin{cases} 1,0 & \text{si } P(x, y) > 0,5 \\ 0,0 & \text{en otro caso} \end{cases} \quad (1)$$

Donde $P(x, y)$ representa el valor normalizado del píxel en la coordenada espacial (x, y) . El conjunto total de muestras se dividió bajo una distribución estricta de base científica: 80 % para optimización de pesos (Entrenamiento), 10 % para el control de sobreajuste (Validación) y un 10 % remanente aislado exclusivamente para el examen final (Prueba).

2.2. Estructura de la U-Net Adaptada

La red empleada preserva la topología simétrica en forma de $\ddot{U}$. El camino de contracción (*Encoder*) extrae gradualmente mapas de características semánticas de alto nivel a expensas de la reducción de la resolución espacial por medio de operaciones consecutivas de convolución y *Max-Pooling*.

El camino de expansión (*Decoder*) reestablece la dimensionalidad a la escala nativa de 256×256 a través de convoluciones transpuestas. El componente diferenciador del sistema son las *Skip Connections* (Conexiones de Salto), encargadas de concatenar directamente los mapas simétricos del encoder en el decoder. Esto rescata la información espacial fina y los contornos geométricos de las lesiones que de otra forma se disiparían en el cuello de botella (*Bottleneck*). La última capa convolucional fue modificada para mapear los canales hacia un único canal de salida ($\text{out_channels} = 1$), acoplándose a la naturaleza binaria del problema.



Figura 1: Flujo de trabajo

3. RESULTADOS CUALITATIVOS Y CUANTITATIVOS

3.1. Evaluación Matemática del Entrenamiento

Para supervisar el aprendizaje se utilizó la función de pérdida de entropía cruzada binaria con logits integrados (BCEWithLogitsLoss), combinada con el optimizador adaptativo *Adam* ($\eta = 1e^{-4}$). El criterio principal de éxito se estableció a través del Coeficiente DICE, definido formalmente como:

$$\text{DICE} = \frac{2|A \cap B|}{|A| + |B|} \quad (2)$$

Donde A representa la máscara de referencia del experto y B denota la predicción binarizada generada por la red neuronal. Los datos recolectados cronológicamente por la estructura de datos tabulares se consolidan en la Tabla 1.

Cuadro 1: Tabla Comparativa de Rendimiento del Modelo U-Net por Época

Época	Train Loss	Val Loss	Train DICE	Val DICE
1	0.3642	0.3412	0.6124	0.6358
5	0.3120	0.3015	0.6980	0.6742
10	0.2915	0.2890	0.7340	0.6985
14	0.2820	0.2811	0.7591	0.7061
15	0.2804	0.2809	0.7612	0.7077

A partir de la Tabla 1 se constata la convergencia matemática del sistema. La reducción monótona simultánea tanto en *Train Loss* como en *Val Loss* descarta la manifestación de un sobreajuste (*overfitting*) crítico, exhibiendo un comportamiento de generalización saludable al estabilizar la métrica metodológica en un sólido 0,7077. Este comportamiento de reducción y convergencia estable se ilustra de manera complementaria en la Figura 2 y la figura 3.




Figura 2: BCE LOSS




Figura 3: DICE SCORE

3.2. Análisis Crítico de Errores (DICE = 0.0000)

En cumplimiento estricto con las directrices de investigación del proyecto, se aislaron los casos de peor rendimiento en el conjunto de prueba. El modelo registró muestras con un coeficiente DICE exacto de 0,0000. El análisis visual de estas muestras, expuesto detalladamente en la Figura ??, determinó que la U-Net produjo mapas de predicción completamente nulos (falsos negativos absolutos).




Figura 4: Errores

Este fenómeno responde a una limitación de carácter multidimensional:

1. **Contraste:** cuando la lesión real tiene muy bajo contraste (se confunde con el tono de la piel), tiene bordes extremadamente difusos, hay una limitación a la hora de segmentar
2. **Desbalance a nivel de píxel:** El área ocupada por la piel sana (fondo) domina significativamente la composición matricial. La red cae en un mínimo local conservador donde predecir el fondo minimiza el error global de forma artificial.
3. **Umbralización Estricta:** La regla heurística rígida impuesta ($> 0,5$) apaga zonas donde la red posea una certeza intermedia (ej. probabilidades calculadas de 0,40 a 0,45).
cuando la lesión real tiene muy bajo contraste (se confunde con el tono de la piel), tiene bordes extremadamente difusos, hay una limitación a la hora de clasificar, también puede influir el desbalanceo de clases, esta es la causa principal. En las imágenes médicas, los píxeles de la lesión (clase positiva) representan una fracción muy pequeña de la imagen en comparación con la piel sana (clase negativa o fondo).

4. DISCUSIÓN Y CONCLUSIONES

4.1. Consideraciones Éticas e Impacto Social

stakeholders el impacto clínico derivado de las desviaciones predictivas del modelo.

Los actores principales en este ecosistema tecnológico corresponden a los pacientes y a los especialistas en dermatología. El despliegue de redes neuronales convolucionales en el entorno clínico impone una responsabilidad bioética rigurosa, especialmente al analizar la naturaleza de los errores. Como se evidenció en la sección de resultados cualitativos, el modelo generó Falsos Negativos absolutos ($DICE = 0,0000$) en lesiones complejas.

Desde la perspectiva del impacto del error, las implicaciones varían drásticamente según la clasificación:

- **Falsos Positivos:** Representan situaciones donde el modelo delimita una lesión inexistente o sobredimensiona tejido sano. Aunque este error satura los servicios de salud y genera un estrés psicológico transitorio en el paciente debido a la sospecha de malignidad, derivando en biopsias innecesarias, su impacto no compromete directamente la integridad vital.
- **Falsos Negativos:** Constituyen el escenario de mayor riesgo ético. Omitir por completo la presencia de una patología como el melanoma maligno induce a un falso sentido de seguridad tanto en el sistema asistencial como en el paciente. Esta desviación técnica posterga el tratamiento oncológico temprano, permitiendo la progresión o metástasis de la enfermedad, lo que reduce directamente las tasas de supervivencia.

Por consiguiente, se concluye éticamente que esta arquitectura U-Net debe ser catalogada y utilizada estrictamente

como una herramienta de tamizaje de segunda opinión médica y soporte diagnóstico, subordinada siempre al arbitrio y validación final del especialista humano.

4.2. Respuestas a las Preguntas de Reflexión

- **DICE vs. Accuracy:** El uso de Pixel Accuracy queda descartado en segmentación médica debido a que no es sensible al severo desbalance de clases. El coeficiente DICE evalúa la concordancia posicional estricta, mapeando la utilidad clínica real del modelo.
- **Importancia de las Skip Connections:** Actúan como puentes de información geométrica de alta frecuencia. Sin ellas, el Decoder generaría contornos excesivamente suavizados o deformados, comprometiendo la precisión en los bordes irregulares característicos de los melanomas.

4.3. Conclusiones y Trabajo Futuro

La adaptación del modelo U-Net al ecosistema dermatológico de ISIC 2018 culminó satisfactoriamente, validando los conceptos teóricos impartidos en la asignatura Deep Learning de la Universidad de Antioquia.

Como propuesta de trabajo futuro enfocado en mitigar los falsos negativos absolutos identificados en el análisis de errores, se plantea el reemplazo de la función BCE por funciones orientadas a la optimización de regiones como *Dice Loss* o *Focal Loss*, la integración de un módulo de aumento de datos dinámico avanzado vía *Albumentations* y la incorporación de arquitecturas de extracción complejas preentrenadas (*Transfer Learning*) como *backbone* del encoder.